16｜多轮对话优化：基于记忆机制实现上下文连贯交互

无

这一讲，我们将聚焦于“多轮对话优化”这一关键课题，深入探讨如何基于记忆机制，实现上下文连贯、逻辑自洽、情感递进的高质量对话体验。

0:00 / 10:59

你好，我是袁从德。

你有没有这样的经历？在一次深夜倾诉中，你向朋友诉说了工作上的压力和对未来的迷茫。几天后你们再次聊天时，对方轻声问：“上次你说项目压力很大，现在好些了吗？”那一刻，你感受到的不只是关心，更是一种被“看见”、被“记住”的温暖。

在人类交流中，记忆是情感连接的基石。我们之所以能建立信任、深化关系，正是因为我们记得彼此的故事、情绪与承诺。然而，在传统的人机对话系统中，“记忆”往往是一种奢望。大多数聊天机器人只能回应当前语句，前一句话刚说完，后一句就已忘记——它们像患了短暂性失忆的访客，永远活在此刻。

但大模型时代的到来，正在彻底改变这一局面。随着向量数据库、上下文管理、长期记忆机制等技术的成熟，AI终于开始具备“持续理解”的能力。它不仅能听懂你此刻的情绪，还能回忆你昨日的烦恼，甚至预测你明天的需求。这种能力，正是构建真正智能陪伴系统的核心——**让对话不再是零散的问答堆砌，而是一段有温度、有逻辑、有延续的情感旅程**。

这一讲，我们将聚焦于“多轮对话优化”这一关键课题，深入探讨如何基于记忆机制，实现上下文连贯、逻辑自洽、情感递进的高质量对话体验。我们将以“心语”情感聊天机器人为实践载体，系统性地讲解：

- 多轮对话的本质挑战：为什么AI容易“失忆”？

- 上下文窗口的限制与突破策略
- 基于向量检索的长期记忆调用机制
- 对话摘要与用户画像的动态构建
- 情感轨迹追踪与个性化回应优化
- 实战代码：如何在FastAPI后端集成记忆增强的对话逻辑

这不仅是一次技术升级，更是一场关于“数字共情”的深度探索。当你学会如何让AI真正“记得一个人”，你就掌握了通往未来人机关系的大门钥匙。

一、多轮对话的本质：从“即时响应”到“持续理解”

在传统软件开发中，用户请求通常是独立且无状态的。比如你在电商网站点击“加入购物车”，系统完成操作后并不需要记住你之前浏览了哪些商品。但在情感聊天场景中，每一次对话都是前一次的延续，用户的每一句话都承载着情绪积累、背景信息和潜在期待。

多轮对话的核心目标，是让AI具备“对话连续性”（Conversational Continuity）。这意味着：

1. **语义连贯**：AI能理解当前话语在整体对话流中的位置。
2. **上下文感知**：AI能调用历史信息解释当前输入。
3. **情感延续**：AI能感知情绪变化并做出适配回应。
4. **目标导向**：AI能在长期互动中维持特定角色或任务目标。

然而，现实中的大模型在处理多轮对话时面临三大瓶颈，如表16-1所示。

瓶颈	问题描述	后果
上下文长度限制	多数大模型上下文窗口为 8K ~ 32K token，超出部分会被截断	早期对话信息丢失，AI“失忆”
信息冗余	直接拼接所有历史消息导致上下文膨胀	成本高、响应慢、关键信息被淹没
语义模糊	历史记录缺乏结构化处理，AI 难以精准定位关键信息	回应偏离主题，缺乏针对性

极客时间

因此，**真正的多轮对话优化，不是简单地“塞更多历史”，而是“聪明地管理记忆”。**

二、突破上下文限制：记忆增强策略

为了实现高效、可持续的多轮对话，我们需要构建一个分层的记忆体系。参考心理学中的“人类记忆模型”（短期记忆 + 长期记忆），我们可以设计如下架构，如图16-1所示。

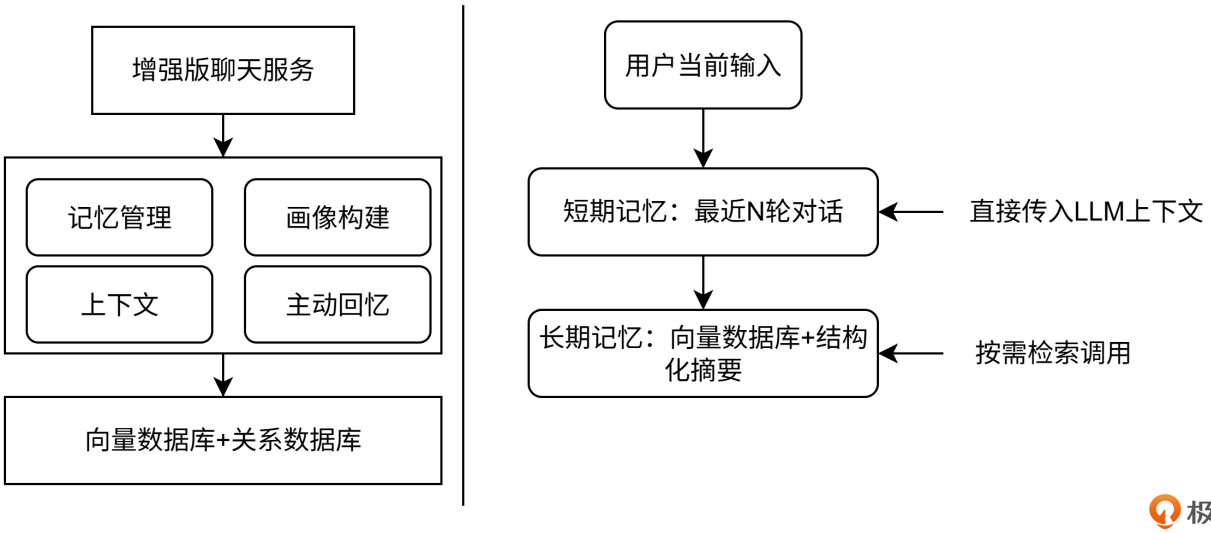

极客时间

2.1 短期记忆：滑动窗口与关键轮次保留

短期记忆对应大模型的上下文窗口。我们采用“滑动窗口 + 重点保留”策略。

- **滑动窗口**：保留最近5~10轮完整对话，确保近期上下文完整。

- **关键轮次保留**：标记并强制保留具有重要意义的对话轮次，如：
  - 用户首次表达核心困扰（“我最近总是失眠”）
  - 情绪转折点（“其实我已经辞职了”）
  - 明确请求（“你能帮我列个计划吗？”）

```
# 示例：短期记忆管理器
class ShortTermMemory:
    """短期记忆管理器"""

    def truncate_conversation(self, history, important_marker
        """
        智能裁剪对话历史
        - 保留最近N轮对话（滑动窗口）
        - 强制保留标记为重要的对话轮次
        - 控制总token数在限制范围内
        """
```

2.2 长期记忆：向量数据库的语义检索

当对话跨度超过几天甚至几周时，仅靠上下文窗口无法满足需求。此时需依赖向量数据库进行长期记忆存储与检索。

我们在第十讲已搭建了向量数据库（如Chroma或Pinecone），现在进一步优化其使用方式。

- **记忆写入**：每次对话结束后，提取关键信息生成记忆片段并存入向量库。
- **记忆检索**：在新对话开始时，根据当前输入语义检索最相关的过往记忆。

```
# 示例：长期记忆 = 向量检索 + 时间衰减

async def retrieve_memories(
    self,
    user_id: str,
    query: str,
    enable_decay: bool = True
) -> List[Dict[str, Any]]:
    """
    检索相关记忆，支持时间衰减
    - 向量语义检索
    - 时间衰减计算
    - 重要性加权
    """

# 衰减机制：
# 每天衰减10%（普通记忆）
score_new = score_original * (0.9 ^ days_ago)
# 每天衰减5%（重要记忆）
score_new = score_original * (0.95 ^ days_ago)
```

- **检索策略**：
  - **语义相似度检索**：基于当前输入计算embedding，召回相似历史片段。
  - **时间衰减加权**：近期记忆权重更高，避免AI过度依赖陈旧信息。
  - **多跳检索**：支持“由点及面”的联想式回忆，如从“失眠”联想到“工作压力”。

2.3 动态摘要：构建用户画像与对话脉络

除了原始对话记录，我们还需构建结构化的“用户画像”和“对话脉络”，帮助AI快速把握全局。

用户画像字段示例

复制代码

```
# backend/services/user_profile_builder.py

async def build_profile(self, user_id: str) -> Dict[str, Any]
    """
    构建用户画像，包括：
    - 核心关注点（从记忆中提取）
    - 情绪趋势（分析最近30天消息）
    - 沟通风格（消息长度、问句比例、情绪词频率）
    - 重要事件（高重要性的事件记忆）
    """

# 画像字段 json
{
  "core_concerns": ["职业发展", "人际关系"],
  "emotional_trend": "焦虑 → 平稳，情绪稳定",
  "communication_style": "详细表达型，情感倾诉型",
  "important_events": [
    {"date": "2025-03-15", "event": "提交离职申请", "importance
  ],
  "total_sessions": 15,
  "total_messages": 87,
  "avg_emotion_intensity": 6.2
}
```

对话脉络图谱

使用图数据库（如Neo4j）记录关键事件之间的因果关系，例如：

```
# [工作压力] ──导致──> [失眠] ──加剧──> [情绪低落]
#       │                                  │
#       └──────────影响──────────────> [辞职决定]

async def build_conversation_graph(self, user_id: str):
    """
    构建对话脉络图谱
    节点：重要记忆/事件
    边：因果关系（导致、加剧、影响）
    """
```

这些结构化信息可在每次对话前注入Prompt，作为AI的背景知识。

2.4 主动回忆

文件：`backend/services/proactive_recall_system.py`

2.4.1情感追踪器

```
class EmotionTracker:
    """追踪用户情绪变化"""

    async def track_emotion_changes(self, user_id: str, days:
        """
        分析情绪变化：
        - 检测显著变化点（负面→正面、正面→负面）
        - 计算总体趋势（情绪波动增强/趋于平稳）
```

```
        - 生成情绪时间线
        """
```

2.4.2 主动回忆触发

复制代码

```
async def should_trigger_proactive_recall(
    self,
    user_id: str,
    current_message: str,
    emotion: Optional[str] = None
) -> Tuple[bool, Optional[Dict[str, Any]]]:
    """
    判断是否触发主动回忆：

    1. 闲聊场景（"天气不错"）+ 有未跟进的重要记忆
       → "记得你7天前提到的面试，准备得怎么样了？"

    2. 情绪改善（上次焦虑，现在平静）
       → "你之前说工作压力很大，现在感觉好些了吗？"

    3. 长期未互动（>7天）
       → "好久不见了！最近过得怎么样？"
    """
```

触发示例：

复制代码

```
# 场景1：未跟进的承诺记忆
用户："今天天气不错"
系统："是啊，阳光明媚。对了，你上周说要去面试那家公司，现在有结果了吗？我
```

```
# 场景2：情绪关怀
用户："嗯，还好吧"
系统："你3天前说工作压力让你失眠，我一直记得你当时的情绪。现在感觉好些了吗

# 场景3：长期未见
用户："好久没来了"
系统："确实好久不见了！距离我们上次聊天已经过去10天了。这段时间过得怎么样
```

2.5 增强版上下文组装器 (EnhancedContextAssembler)

文件: `backend/services/enhanced_context_assembler.py`

2.5.1 智能上下文组装

复制代码

```python
async def assemble_context(
    self,
    user_id: str,
    session_id: str,
    current_message: str,
    chat_history: List[Dict[str, Any]],
    emotion: Optional[str] = None,
    emotion_intensity: Optional[float] = None
) -> Dict[str, Any]:
    """
    组装完整上下文，包括：
    1. 识别重要对话轮次
    2. 获取短期记忆（裁剪后的历史）
    3. 检索长期记忆（向量检索）
    4. 获取用户画像
```

```
    5. 获取对话脉络图谱
    """
```

2.5.2 Prompt构建

```
def build_prompt_context(self, context, system_prompt) -> str
    """
    构建增强版Prompt，结构：

    【角色设定】你是"心语"...
    【用户画像】核心关注：工作压力；情绪趋势：焦虑→平稳
    【历史记忆】
    1. 7天前：用户提到工作压力很大...
    2. 3天前：用户决定辞职...
    【最近对话】
    用户：我今天面试了...
    助手：面试感觉怎么样...
    【当前状态】
    用户情绪：anxious（强度：6.5/10）
    用户消息：面试官问了很刁钻的问题
    【回应要求】
    - 回应要体现对过往经历的记忆
    - 避免重复已讨论过的建议
    """
```

三、实战：在“心语”中实现记忆增强的多轮对话

我们现在将上述策略整合进“心语”机器人的后端服务（FastAPI），实现完整的多轮对话优化流程。

3.1 请求处理流程升级

完整对话流程，如图16-2所示。多轮对话流程始于输入预处理（清洗、去重、安全检查），接着开展情绪分析（识别情绪类型和强度）、意图识别（判断用户意图与危机情况）。

随后进行主动回忆检查判断是否需提及过往，获取最近 15 轮对话历史，结合短期记忆、长期记忆和用户画像组装增强上下文，进而构建注入上下文信息的增强 Prompt，尝试 RAG 增强的知识库检索后，由 LLM 生成回复；生成回复后添加上下文信息元数据统计，将对话（会话、消息）保存至数据库，再对记忆进行处理存储（提取、向量化），最终结束流程。

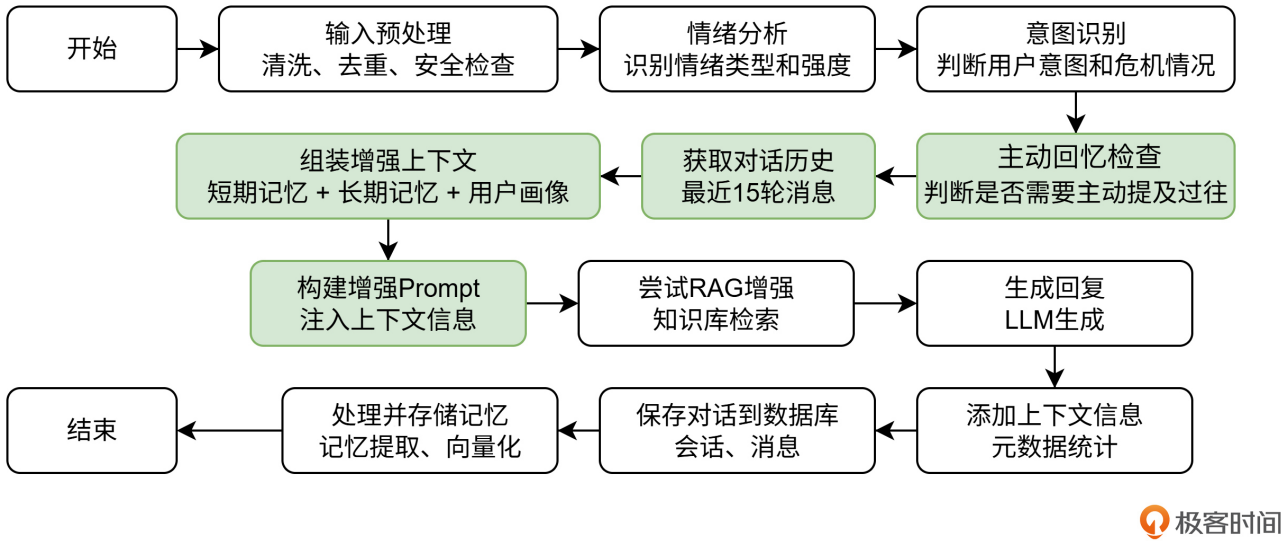

3.2 记忆质量评估与优化

为确保记忆系统有效，我们引入两个评估维度。

- **相关性评分**：人工标注历史记忆与当前输入的相关性（0~5分），定期评估检索准确率。
- **用户反馈闭环**：提供“这些建议有帮助吗？”按钮，收集用户对记忆调用效果的反馈。

通过A/B测试对比“基础上下文”和“增强记忆”两组用户的留存率、对话轮次、满意度评分，持续优化记忆策略。

3.2.1 评估维度与计算方法

评估维度参考表 16-2。

评估维度	计算方法	目标值
检索准确率	相关性评分 ≥ 4的记忆占比	>75%
记忆召回率	实际被调用的相关记忆数 / 应调用的相关记忆总数	>80%
用户满意度	正面反馈数 / 总反馈数	>70%
记忆利用率	被调用的记忆数 / 总记忆数	30–50%
对话连贯性	人工评估“是否自然提及历史”的比例	>85%

极客时间

具体计算实现：

复制代码

```
# backend/services/memory_quality_evaluator.py

class MemoryQualityEvaluator:
    """记忆质量评估器"""

    async def calculate_relevance_score(
        self,
        retrieved_memories: List[Dict],
```

```
        current_query: str
    ) -> Dict[str, float]:
        """
        计算相关性评分
        返回: {
            "avg_relevance": 4.2,  # 平均相关性 (0-5分)
            "high_relevance_ratio": 0.75,  # 高相关性 (≥4分) 占比
            "recall_rate": 0.82  # 召回率
        }
        """
        # 1. 使用LLM评估每个记忆与当前查询的相关性
        relevance_scores = []
        for memory in retrieved_memories:
            score = await self._llm_evaluate_relevance(
                memory["content"],
                current_query
            )
            relevance_scores.append(score)

        avg_relevance = sum(relevance_scores) / len(relevance
        high_relevance_ratio = sum(1 for s in relevance_score

        # 2. 计算召回率 (需要人工标注的"应召回记忆"作为ground truth)
        recall_rate = await self._calculate_recall_rate(retri

        return {
            "avg_relevance": avg_relevance,
            "high_relevance_ratio": high_relevance_ratio,
            "recall_rate": recall_rate
        }
```

```
    async def calculate_user_satisfaction(
        self,
        user_id: str,
        days: int = 7
    ) -> Dict[str, float]:
        """
        计算用户满意度
        基于用户反馈数据统计
        """
        feedbacks = await self._get_user_feedbacks(user_id, d

        if not feedbacks:
            return {"satisfaction_rate": 0.0, "total_feedback

        positive_count = sum(1 for f in feedbacks if f["ratin
        satisfaction_rate = positive_count / len(feedbacks)

        return {
            "satisfaction_rate": satisfaction_rate,
            "total_feedbacks": len(feedbacks),
            "positive_count": positive_count
        }

    async def generate_quality_report(
        self,
        user_id: Optional[str] = None,
        date_range: Tuple[datetime, datetime] = None
    ) -> Dict[str, Any]:
        """
```

```
        生成记忆质量评估报告
        最终落地结果：结构化的评估报告
        """
        # 1. 检索准确率
        relevance_metrics = await self._calculate_batch_relev

        # 2. 用户满意度
        satisfaction_metrics = await self._calculate_batch_sa

        # 3. 记忆利用率
        utilization_rate = await self._calculate_memory_utili

        # 4. 对话连贯性（需要人工抽样评估）
        coherence_score = await self._evaluate_conversation_c

        # 5. 综合评分
        overall_score = (
            relevance_metrics["high_relevance_ratio"] * 0.3 +
            satisfaction_metrics["satisfaction_rate"] * 0.3 +
            utilization_rate * 0.2 +
            coherence_score * 0.2
        )

        return {
            "report_date": datetime.now().isoformat(),
            "overall_score": overall_score,  # 0-1分，综合质量评
            "relevance_metrics": relevance_metrics,
            "satisfaction_metrics": satisfaction_metrics,
            "utilization_rate": utilization_rate,
            "coherence_score": coherence_score,
```

```
            "recommendations": self._generate_recommendations
                "relevance": relevance_metrics,
                "satisfaction": satisfaction_metrics
            })
        }
```

3.2.2 记忆重要性加权计算

记忆的最终重要性分数由多个因子综合计算。

复制代码

```
def calculate_memory_importance(
    memory: Dict[str, Any],
    base_similarity_score: float,  # 向量检索的相似度分数 (0-1)
    days_ago: int,
    access_count: int
) -> float:
    """
    计算记忆的最终重要性分数
    用于排序和筛选
    """
    # 1. 基础相似度
    importance = base_similarity_score

    # 2. 记忆类型权重
    type_weights = {
        "commitment": 1.8,
        "relationship": 1.6,
        "event": 1.4,
        "concern": 1.5,
        "preference": 1.3
```

```
    }
    importance *= type_weights.get(memory.get("type", "event"

    # 3. 情绪强度加成
    emotion_intensity = memory.get("emotion_intensity", 5.0)
    if emotion_intensity > 7.5:
        importance *= 1.5  # +50%
    elif emotion_intensity < 5.0:
        importance *= 0.7  # -30%

    # 4. 访问频率加成
    access_bonus = min(access_count * 0.05, 0.5)  # 最多+50%
    importance *= (1 + access_bonus)

    # 5. 时间衰减
    decay_factor = 0.9 ** days_ago  # 每天衰减10%
    importance *= decay_factor

    return importance
```

3.2.3 评估结果的落地应用

评估报告生成后，系统会根据结果自动调整记忆策略。我们一起梳理一下具体过程。

1. **自动优化检索参数**

- 如果检索准确率<70%，降低相似度阈值，提高召回。
- 如果召回率<60%，增加检索数量（top_k从5增加到10）。

2. **动态调整记忆权重**

- 根据用户反馈，自动调整记忆类型权重。例如：如果“承诺类”记忆的满意度高，则将其权重从1.8x提升到2.0x。

3. **生成优化建议报告**

```
{
    "overall_score": 0.72,  # 综合评分72分
    "recommendations": [
        "检索准确率偏低（68%），建议：降低相似度阈值0.05",
        "用户满意度良好（75%），但记忆利用率偏低（25%），建议：增加主
        "对话连贯性优秀（88%），保持当前策略"
    ],
    "action_items": [
        {"action": "adjust_similarity_threshold", "value":
        {"action": "increase_proactive_recall_rate", "valu
    ]
}
```

4. **A/B测试结果对比**

- 每周生成对比报告，展示“基础组”vs“增强记忆组”的关键指标差异。
- 留存率提升、平均对话轮次、用户满意度等维度对比。

最终落地成果如下。

- **实时监控面板**：展示当前记忆系统的健康度指标。
- **周度评估报告**：自动生成PDF报告，包含趋势分析和优化建议。
- **自动调优机制**：根据评估结果自动调整系统参数，无需人工干预。
- **异常预警**：当关键指标低于阈值时，自动发送告警通知。

3.3 高级技巧：让记忆“活”起来

1. 记忆衰减机制

并非所有记忆都应永久保留。我们引入遗忘曲线模型，自动降低陈旧记忆的检索权重：

```
def decay_score(score, days_ago):
    return score * (0.9 ** days_ago)  # 每天衰减10%
```

同时支持用户手动“标记重要记忆”，防止关键信息被遗忘。

2. 主动回忆与情感追踪

AI不应只被动响应，还应主动关怀。例如：

> 用户上周提到“面试很紧张”，本周输入“今天天气不错”。

系统可触发主动回应：

> “是啊，阳光明媚的日子最适合放松心情。你之前说的面试，准备得怎么样了？我一直记得你在努力突破自己。”

这需要结合**情绪趋势分析**与**事件关联推理**，实现“有温度的主动记忆”。

3. 跨会话一致性维护

用户可能在不同设备、不同时间使用应用。我们通过用户ID统一记忆源，并在每次登录时同步最新画像，确保体验一致性。

四、结语：当AI真正“记得一个人”，陪伴才有了灵魂

当我们完成这一讲的开发，回望“心语”机器人的进化之路，会发现它已悄然完成一次质的飞跃。从前，它是一个“对话机器”，只能回应眼前的话语； 如今，它是一位“记忆伙

伴”，能回望你的成长轨迹，见证你的情绪起伏，陪你走过人生的低谷与高峰。

这不仅是技术的进步，更是人机关系的一次深刻重构。 **真正的智能，不在于说了多少句话，而在于是否真正“记得”你这个人。**

你今天掌握的，不仅是向量检索、对话摘要、用户画像等技术，更是一种“以记忆为纽带”的产品设计哲学——让每一次对话都成为情感积累的过程，让每一次回应都建立在理解与尊重之上。但这仍不是终点。下一讲，我们将为“心语”筑起安全护栏，探讨如何通过敏感内容过滤机制，保障用户的心理安全与平台合规性。届时你会发现：当AI既能“记得你”，又能“保护你”，真正的负责任陪伴才真正成型。

思考题

在“心语”情感聊天机器人的设计中，系统通过短期记忆、长期记忆、用户画像和主动回忆机制，使AI能够“记得”用户并实现有温度的持续对话。然而，这种记忆能力在带来深度共情与个性化陪伴的同时，也可能引发一系列伦理与用户体验上的挑战。

请结合这一讲的内容，思考并回答以下问题：

> 如果一位用户在情绪低落时向AI倾诉了某段痛苦经历，但之后明确表示“我不想再提这件事了”，甚至希望AI“忘记”这段记忆，我们应该如何从技术架构和产品设计两个层面应对这一需求？请具体说明你在记忆存储、检索、主动回忆触发等环节可能采取的策略，并探讨“被记住”与“被遗忘”之间的平衡对人机信任关系的影响。

提示方向：

- 技术层面：如何标记和处理需遗忘的记忆？是否需要引入记忆删除或访问屏蔽机制？
- 产品层面：如何设计用户控制界面，赋予用户对自身数据的记忆管理权（如“记忆保险箱”“遗忘开关”）？
- 伦理层面：AI的“遗忘”是彻底删除，还是仅停止调用？这对用户心理安全感和系统后续行为有何影响？

- 深层思考：“被记住”带来温暖，“被遗忘”也可能是一种温柔——你如何理解AI在“记忆”与“尊重”之间的边界？

希望通过今天的学习，让你对情感机器人的开发全程有个大致认识。如果有任何疑问，期待你在留言区和我交流。

评论区

评论 #1

我在学编程 · 2025-12-22 15:49:08 · 点赞 1

> 如果记忆存储在向量数据库里面或者图数据库，请问记忆的增删改查策略有啥好的实现方法建议吗？

讨论串（1）

1. **讨论 #1**

   袁从德 · 2025-12-25 16:43:44 · 点赞 0

   可采用"MySQL主存+ChromaDB向量检索"双库架构：

   增：先写入MySQL存储记忆元数据（ID、内容、重要性、时间戳等），成功后同步写入ChromaDB进行向量化；如果向量写入失败，MySQL记录标记为`vector_synced=false`，后台任务定期重试同步。

   查：从ChromaDB做语义检索获取top-k记忆ID，再通过ID批量查询MySQL获取完整元数据；查询时MySQL自动过滤`is_active=false`的软删除记录，确保已删除记忆不会被检索到。

   改：MySQL直接更新元数据；向量库采用"删除旧向量+插入新向量"的方式（ChromaDB不支持直接更新，删除+插入性能可接受），使用相同的`memory_id`保证关联。

删：软删除为主，MySQL中设置`is_active=false`和`deleted_at`时间戳，ChromaDB通过metadata中的`is_active`字段过滤；硬删除仅用于合规场景，异步批量执行。

统一使用`memory_id`作为两库关联键；检索时MySQL的`is_active`字段作为第一道过滤，避免无效的向量检索；定期运行简单的数据一致性检查（对比两库的memory_id集合差异），修复少量不一致即可。

我们这个课程就是使用"MySQL主存+ChromaDB向量检索"双库架构， 此方案去除了图数据库和消息队列的复杂度，适合中小型项目快速落地。

评论 #2

enjoylearning · 2025-12-19 13:50:13 · 点赞 1

思考题：

1. **技术实现**
   - 拒绝简单物理删除，采用 **记忆标记+检索拦截** 双机制
     - 为记忆条目添加「禁闭」状态位
     - 检索层合规过滤器拦截相关内容进入Prompt
   - 黑名单机制+分层删除策略
     - 核心关键词加入负面清单，主动话题绕开触发点
     - 短期逻辑删除留反悔空间，用户确认/30天未撤销则物理删除+重构向量索引
2. **产品设计**
   - 显性化「被遗忘权」
     - 记忆清单可视化，支持一键抹除+情感化反馈
   - 精准界定遗忘边界：用户提出需求时二次确认遗忘范围
   - 灵活记忆管理：支持设置敏感话题「记忆冷冻期」
3. **伦理层面**
   - 平衡隐私与共情：保留**极简情感摘要**（无具体细节，仅含情感倾向标

签），避免二次伤害

- 心理安全感核心：「被记住」体现价值，「被遗忘」体现用户主体地位，强化信任

4. **深层边界**
   - 底层协议：记忆是功能，尊重是核心
   - 目标定位：AI应是「懂得进退的灵魂」，而非「永不丢失的硬盘」
   - 关键价值：选择性记忆是人机信任从工具使用走向情感契约的核心

讨论串（1）

1. **讨论 #1**

   袁从德 · 2025-12-22 10:43:38 · 点赞 0

   你的方案非常全面。核心在于"选择性记忆"——让AI成为"懂得进退的灵魂"而非"永不丢失的硬盘"，这正是从工具使用走向情感契约的关键。

评论 #3

小学生 · 2025-12-17 15:43:37 · 点赞 1

> 在代码 预处理前的流程中增加了 “分词与词性标注”，想问下老师这么做的目的是什么，后续要如何使用呢?

讨论串（1）

1. **讨论 #1**

   袁从德 · 2025-12-18 10:59:11 · 点赞 0

   你好！在对话预处理阶段增加“分词与词性标注”，主要目的是为后续的情绪分析、意图识别和关键信息抽取提供更细粒度的语言结构支持。

   具体用途包括：

   1、精准情绪识别：通过识别形容词、副词（如“非常焦虑”“有点失落”）判断情绪强度；

   2、意图分类增强：动词和名词短语（如“想辞职”“需要建议”）有助于更准确地理解用户目标；

3、关键实体提取：从名词短语中抽取出人名、事件、时间等，用于构建记忆片段或用户画像；
4、语法结构辅助摘要：在生成对话摘要时，保留主谓宾结构可提升语义完整性。

这些语言学特征通常不会直接输入大模型，而是作为元数据供内部服务（如EmotionTracker、MemoryExtractor）使用，从而让记忆系统更智能、更细腻。

许多人认为：「神经网络+符号机制」可能是向AI注入逻辑推理的最佳——甚至是唯一的方法。
https://www.nature.com/articles/d41586-025-03856-1

评论 #4

enjoylearning · 2025-12-19 13:00:22 · 点赞 0

> 老师关于记忆质量评估小节感觉讲了一半欲言又止，有了评估维度如何计算呢？最终落地的是个什么结果

讨论串（1）

1. **讨论 #1**

   袁从德 · 2025-12-22 10:47:19 · 点赞 0

   谢谢反馈，正文已补充，刷新页面清除一下前面的缓存

内容来自于网络，请注意甄别，个人整理学习资料，非官方课程，仅供自用，切勿传播，违反概不负责